Министерство науки и высшего образования
Российской Федерации
Федеральное государственное бюджетное образовательное
учреждение высшего образования
"Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)"
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА, ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА _____СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ (ИУ5)_____

ОТЧЕТ

Лабораторная работа №2

«Обработка признаков»

по курсу «Методы машинного обучения»

ИСПОЛНИТЕЛЬ: Рабцевич К.Р.
ФИО

группа ИУ5-21М _____
подпись

"__"_____2023 г.

ПРЕПОДАВАТЕЛЬ: Гапанюк Ю.Е.
ФИО

_____
подпись

"__"_____2023 г.

Москва - 2023

Лабораторная работа №2

Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.

Цель лабораторной работы: изучение способов предварительной обработки данных для дальнейшего формирования моделей.

Задание:

1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
   - обработку пропусков в данных;
   - кодирование категориальных признаков;
   - масштабирование данных.

Импорт библиотек

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Загрузка и первичный анализ данных

Используем данные с kaggle Фильмы и телешоу Netflix

In [2]:
```
data = pd.read_csv('data/netflix_titles.csv', sep=",")
```

In [3]:
```
# размер набора данных
data.shape
```

Out[3]:
```
(8807, 12)
```

In [4]:
```
# типы колонок
data.dtypes
```

Out[4]:
```
show_id         object
type            object
title           object
director        object
```

```
cast            object
country         object
date_added      object
release_year     int64
rating          object
duration        object
listed_in       object
description     object
dtype: object
```

In [5]:

```
# проверим есть ли пропущенные значения
data.isnull().sum()
```

Out[5]:

```
show_id            0
type               0
title              0
director        2634
cast             825
country          831
date_added        10
release_year       0
rating             4
duration           3
listed_in          0
description        0
dtype: int64
```

In [6]:

```
# Первые 5 строк датасета
data.head()
```

Out[6]:

	show_id	type	title	director	cast	country	date_added	release_year	rating	durati
0	s1	Movie	Dick Johnson Is Dead	Kirsten Johnson	NaN	United States	September 25, 2021	2020	PG-13	90 r
1	s2	TV Show	Blood & Water	NaN	Ama Qamata, Khosi Ngema, Gail Mabalane, Thaban...	South Africa	September 24, 2021	2021	TV-MA	Seasc
2	s3	TV Show	Ganglands	Julien Leclercq	Sami Bouajila, Tracy Gotoas, Samuel Jouy, Nabi...	NaN	September 24, 2021	2021	TV-MA	1 Seas
3	s4	TV Show	Jailbirds New Orleans	NaN	NaN	NaN	September 24, 2021	2021	TV-MA	1 Seas
4	s5	TV Show	Kota Factory	NaN	Mayur More, Jitendra	India	September 24, 2021	2021	TV-MA	Seasc

show_id	type	title	director	cast	country	date_added	release_year	rating	durati
				Kumar, Ranjan Raj, Alam K...					

In [7]:
```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 8807
```

Обработка пропусков в данных

In [8]:
```
# Выберем колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0:
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.forma
```

```
Колонка director. Тип данных object. Количество пустых значений 2634, 29.91%.
Колонка cast. Тип данных object. Количество пустых значений 825, 9.37%.
Колонка country. Тип данных object. Количество пустых значений 831, 9.44%.
Колонка date_added. Тип данных object. Количество пустых значений 10, 0.11%.
Колонка rating. Тип данных object. Количество пустых значений 4, 0.05%.
Колонка duration. Тип данных object. Количество пустых значений 3, 0.03%.
```

In [9]:
```
# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```

Out[9]:

	director	cast	country	date_added	rating	duration
0	Kirsten Johnson	NaN	United States	September 25, 2021	PG-13	90 min
1	NaN	Ama Qamata, Khosi Ngema, Gail Mabalane, Thaban...	South Africa	September 24, 2021	TV-MA	2 Seasons
2	Julien Leclercq	Sami Bouajila, Tracy Gotoas, Samuel Jouy, Nabi...	NaN	September 24, 2021	TV-MA	1 Season
3	NaN	NaN	NaN	September 24, 2021	TV-MA	1 Season
4	NaN	Mayur More, Jitendra Kumar, Ranjan Raj, Alam K...	India	September 24, 2021	TV-MA	2 Seasons
...	...	...	...	...	...	...
8802	David Fincher	Mark Ruffalo, Jake Gyllenhaal, Robert Downey J...	United States	November 20, 2019	R	158 min
8803	NaN	NaN	NaN	July 1, 2019	TV-Y7	2 Seasons

	director	cast	country	date_added	rating	duration
8804	Ruben Fleischer	Jesse Eisenberg, Woody Harrelson, Emma Stone, ...	United States	November 1, 2019	R	88 min
8805	Peter Hewitt	Tim Allen, Courteney Cox, Chevy Chase, Kate Ma...	United States	January 11, 2020	PG	88 min
8806	Mozez Singh	Vicky Kaushal, Sarah-Jane Dias, Raaghav Chanan...	India	March 2, 2019	TV-14	111 min

8807 rows × 6 columns

In [10]:
```
cat_temp_data = data[['rating']]
cat_temp_data.head()
```

Out[10]:

	rating
0	PG-13
1	TV-MA
2	TV-MA
3	TV-MA
4	TV-MA

In [11]:
```
cat_temp_data['rating'].unique()
```

Out[11]:
```
array(['PG-13', 'TV-MA', 'PG', 'TV-14', 'TV-PG', 'TV-Y', 'TV-Y7', 'R',
       'TV-G', 'G', 'NC-17', '74 min', '84 min', '66 min', 'NR', nan,
       'TV-Y7-FV', 'UR'], dtype=object)
```

In [12]:
```
cat_temp_data[cat_temp_data['rating'].isnull()].shape
```

Out[12]:
```
(4, 1)
```

Подключим библиотеки для обработки пропусков

In [13]:
```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

In [14]:
```
# Импьютация наиболее частыми значениями
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
```

Out[14]:
```
array([['PG-13'],
       ['TV-MA'],
       ['TV-MA'],
       ...,
       ['R'],
       ['PG'],
       ['TV-14']], dtype=object)
```

In [15]:
```
# Пустые значения отсутствуют
```

```
In [15]: np.unique(data_imp2)
```

```
Out[15]: array(['66 min', '74 min', '84 min', 'G', 'NC-17', 'NR', 'PG', 'PG-13',
       'R', 'TV-14', 'TV-G', 'TV-MA', 'TV-PG', 'TV-Y', 'TV-Y7',
       'TV-Y7-FV', 'UR'], dtype=object)
```

```
In [16]: # Импьютация константой
imp3 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='NA')
data_imp3 = imp3.fit_transform(cat_temp_data)
data_imp3
```

```
Out[16]: array([['PG-13'],
       ['TV-MA'],
       ['TV-MA'],
       ...,
       ['R'],
       ['PG'],
       ['TV-14']], dtype=object)
```

```
In [17]: np.unique(data_imp3)
```

```
Out[17]: array(['66 min', '74 min', '84 min', 'G', 'NA', 'NC-17', 'NR', 'PG',
       'PG-13', 'R', 'TV-14', 'TV-G', 'TV-MA', 'TV-PG', 'TV-Y', 'TV-Y7',
       'TV-Y7-FV', 'UR'], dtype=object)
```

```
In [18]: data_imp3[data_imp3=='NA'].size
```

```
Out[18]: 4
```

Кодирование категориальных признаков

Кодирование категорий целочисленными значениями - label encoding

```
In [19]: cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
cat_enc
```

Out[19]:

	c1
0	PG-13
1	TV-MA
2	TV-MA
3	TV-MA
4	TV-MA
...	...
8802	R
8803	TV-Y7
8804	R
8805	PG
8806	TV-14

8807 rows × 1 columns

In [20]:
```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

In [21]:
```
le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
```

In [22]:
```
np.unique(cat_enc_le)
```

Out[22]:
```
array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14, 15, 16])
```

In [23]:
```
le.inverse_transform([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13])
```

Out[23]:
```
array(['66 min', '74 min', '84 min', 'G', 'NC-17', 'NR', 'PG', 'PG-13',
       'R', 'TV-14', 'TV-G', 'TV-MA', 'TV-PG', 'TV-Y'], dtype=object)
```

Кодирование категорий наборами бинарных значений - one-hot encoding

In [24]:
```
ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])
```

In [25]:
```
cat_enc.shape
```

Out[25]:
```
(8807, 1)
```

In [26]:
```
cat_enc_ohe.shape
```

Out[26]:
```
(8807, 17)
```

In [27]:
```
cat_enc_ohe.todense()[0:10]
```

Out[27]:
```
matrix([[0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0.,
         0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0.,
         0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0.,
         0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0.,
         0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0.,
         0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0.,
         0.],
        [0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
         0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0.,
         0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0.,
         0.],
        [0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0.,
         0.]])
```

In [28]:
```
cat_enc.head(10)
```

Out[28]:

	c1
0	PG-13
1	TV-MA
2	TV-MA
3	TV-MA
4	TV-MA
5	TV-MA
6	PG
7	TV-MA
8	TV-14
9	PG-13

Нормализация числовых признаков

In [34]:
```
import scipy.stats as stats
```

In [35]:
```
def diagnostic_plots(df, variable):
    plt.figure(figsize=(15,6))
    # гистограмма
    plt.subplot(1, 2, 1)
    df[variable].hist(bins=30)
    ## Q-Q plot
    plt.subplot(1, 2, 2)
    stats.probplot(df[variable], dist="norm", plot=plt)
    plt.show()
```

In [30]:
```
data.hist(figsize=(5,5))
plt.show()
```

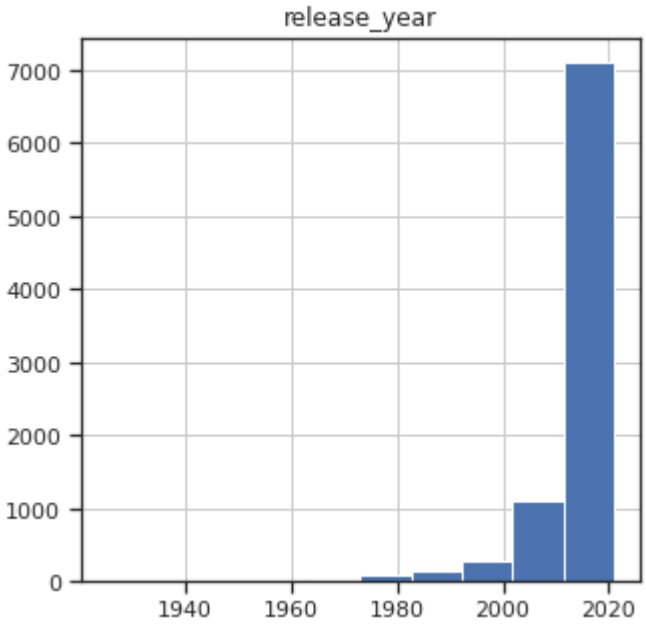

In [36]:
```
diagnostic_plots(data, 'release_year')
```

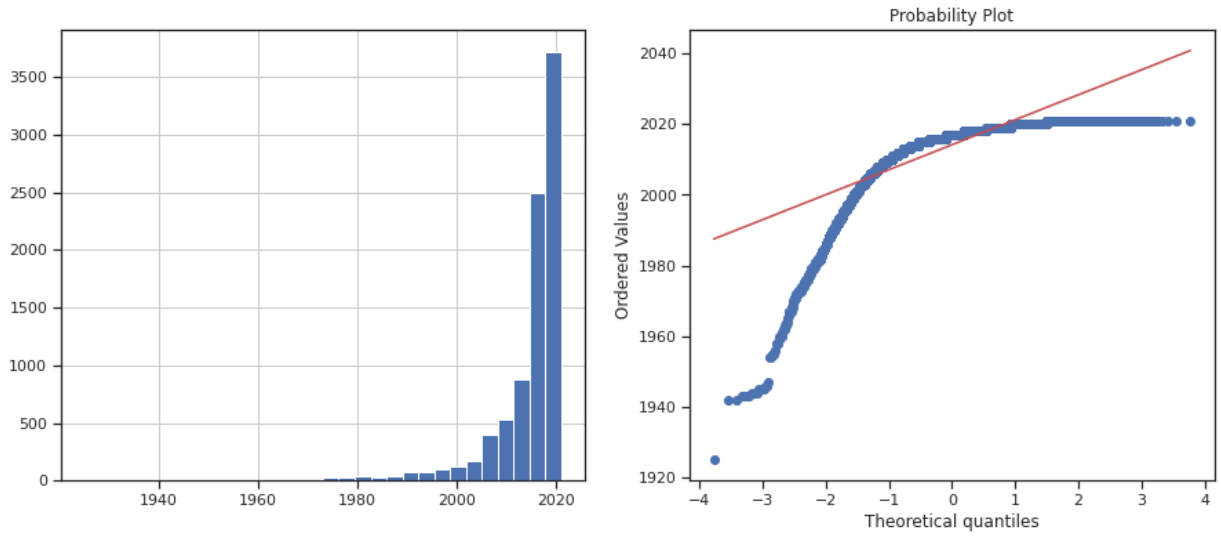

Логарифмическое преобразование

In [38]:
```
data['release_year_log'] = np.log(data['release_year'])
diagnostic_plots(data, 'release_year_log')
```

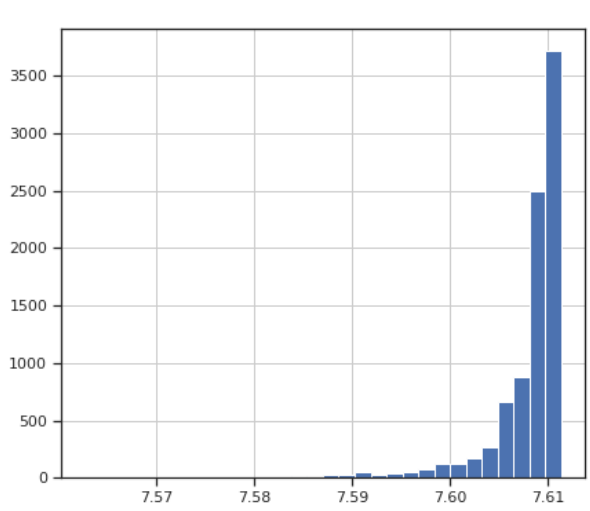

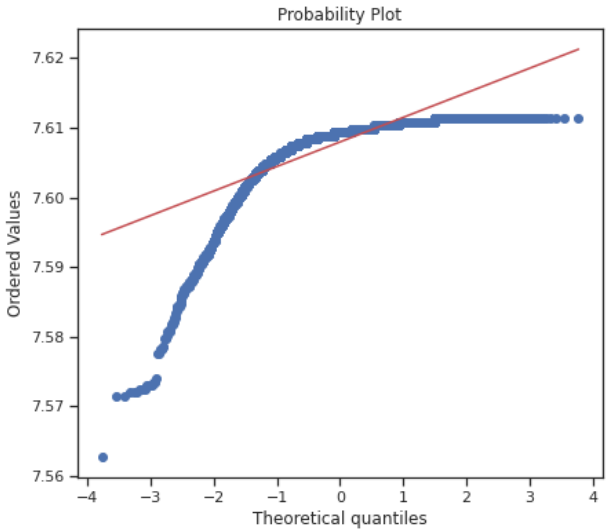

Обратное преобразование

In [39]:
```
data['release_year_reciprocal'] = 1 / (data['release_year'])
diagnostic_plots(data, 'release_year_reciprocal')
```

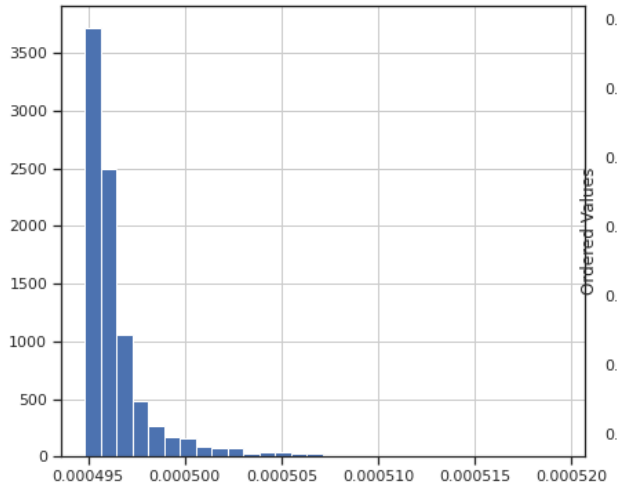

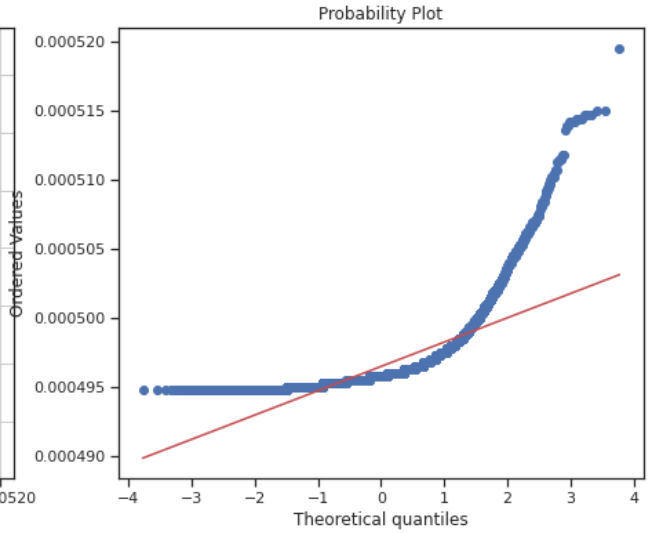

Квадратный корень

In [40]:
```
data['release_year_sqr'] = data['release_year']**(1/2)
diagnostic_plots(data, 'release_year_sqr')
```

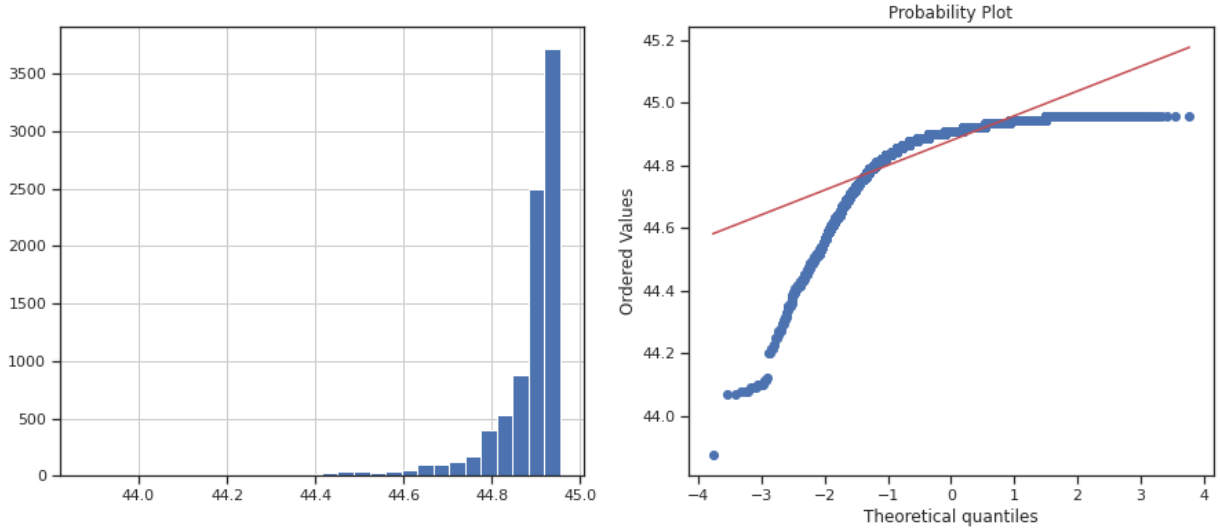

Возведение в степень

In [41]:
```
data['release_year_exp1'] = data['release_year']**(1/1.5)
diagnostic_plots(data, 'release_year_exp1')
```

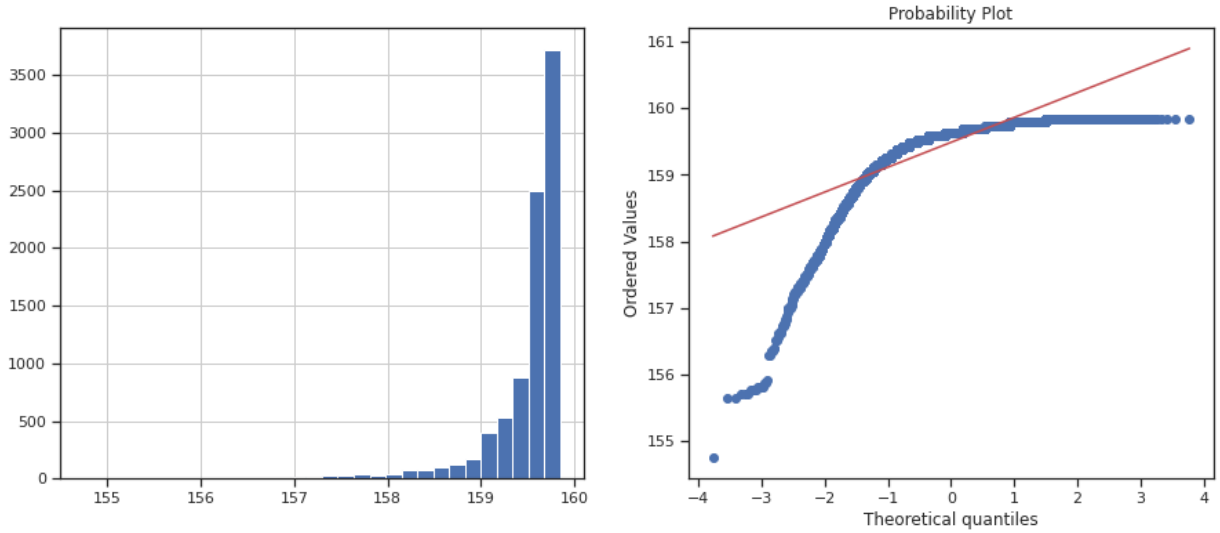

In [42]:
```
data['release_year_exp2'] = data['release_year']**(2)
diagnostic_plots(data, 'release_year_exp2')
```

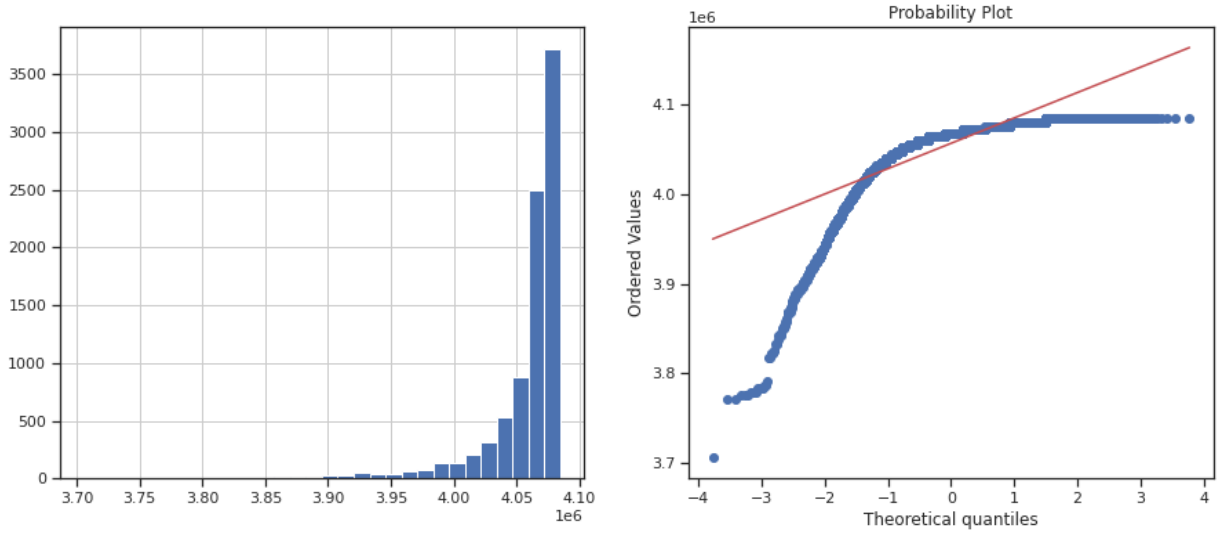

In [43]:
```
data['release_year_exp3'] = data['release_year']**(0.333)
diagnostic_plots(data, 'release_year_exp3')
```

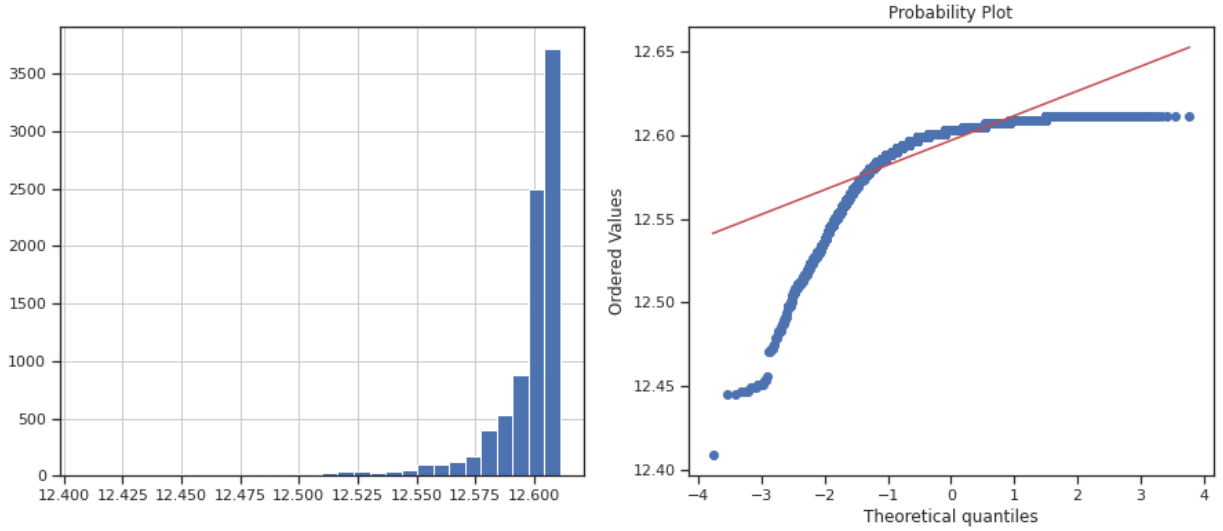

Преобразование Бокса-Кокса

In [44]:
```
data['release_year_boxcox'], param = stats.boxcox(data['release_year'])
print('Оптимальное значение λ = {}'.format(param))
diagnostic_plots(data, 'release_year_boxcox')
```

```
/root/miniconda3/lib/python3.9/site-packages/numpy/core/_methods.py:205: RuntimeWarn
ing: overflow encountered in multiply
  x = um.multiply(x, x, out=x)
/root/miniconda3/lib/python3.9/site-packages/numpy/core/_methods.py:216: RuntimeWarn
ing: overflow encountered in reduce
  ret = umr_sum(x, axis, dtype, out, keepdims)
Оптимальное значение λ = 46.79897643237659
```

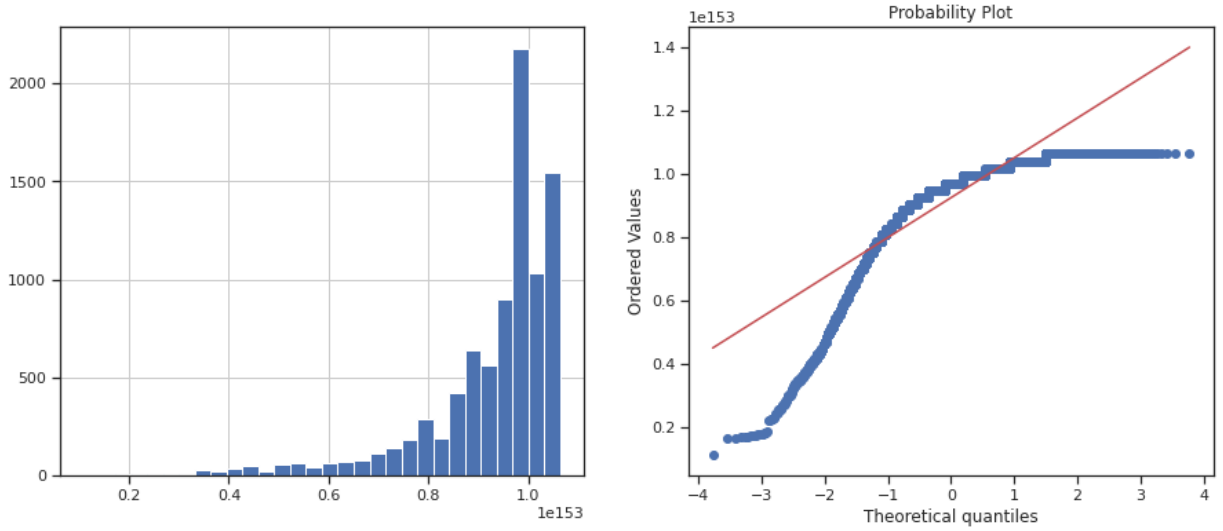

Преобразование Йео-Джонсона

In [45]:
```
# Необходимо преобразовать данные к действительному типу
data['release_year'] = data['release_year'].astype('float')
data['release_year_yeojohnson'], param = stats.yeojohnson(data['release_year'])
print('Оптимальное значение λ = {}'.format(param))
diagnostic_plots(data, 'release_year_yeojohnson')
```

```
/root/miniconda3/lib/python3.9/site-packages/numpy/core/_methods.py:205: RuntimeWarn
ing: overflow encountered in multiply
  x = um.multiply(x, x, out=x)
/root/miniconda3/lib/python3.9/site-packages/numpy/core/_methods.py:216: RuntimeWarn
ing: overflow encountered in reduce
  ret = umr_sum(x, axis, dtype, out, keepdims)
Оптимальное значение λ = 46.795973629169694
```

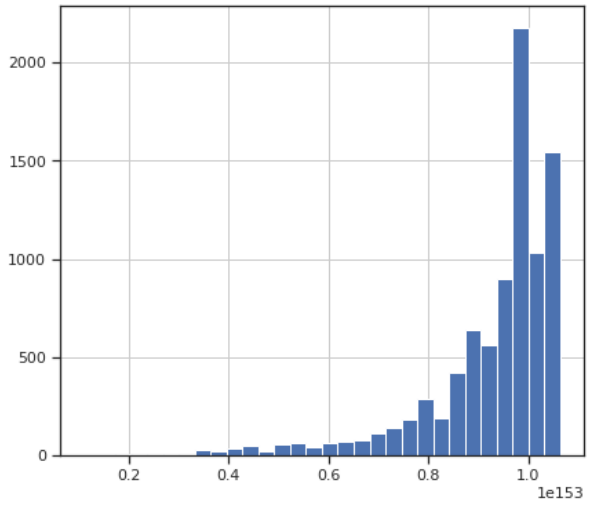

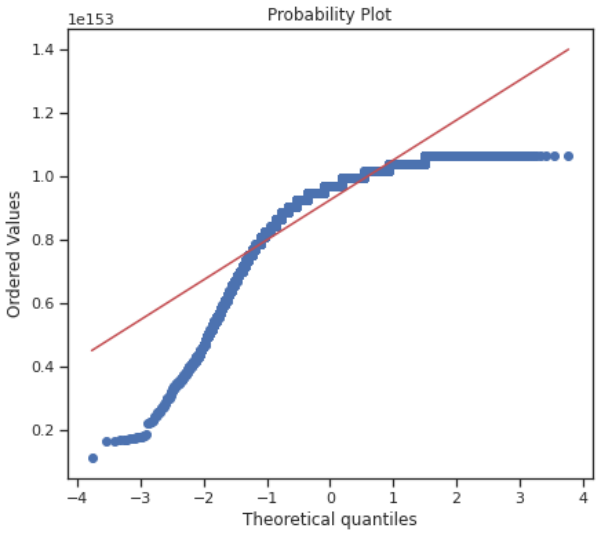

Масштабирование данных

In [37]:
```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

MinMax масштабирование

In [38]:
```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['release_year']])
```

In [39]:
```
plt.hist(data['release_year'], 100)
plt.show()
```

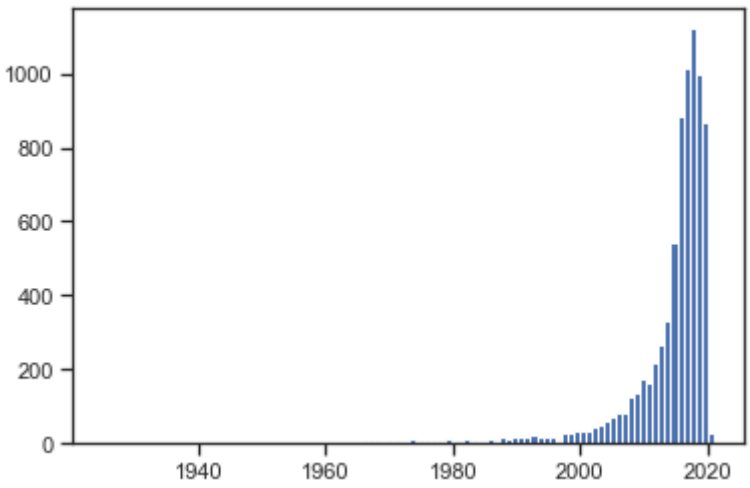

In [40]:
```
plt.hist(sc1_data, 100)
plt.show()
```

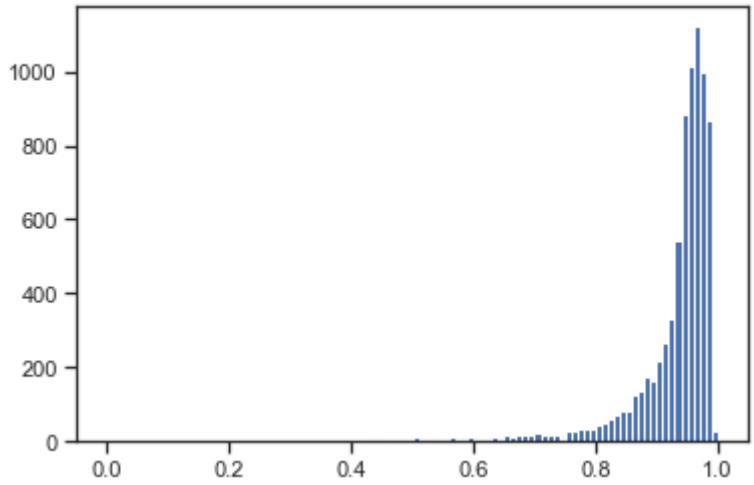

Масштабирование данных на основе Z-оценки - StandardScaler

In [41]:
```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['release_year']])
```

In [42]:
```
plt.hist(sc2_data, 100)
plt.show()
```

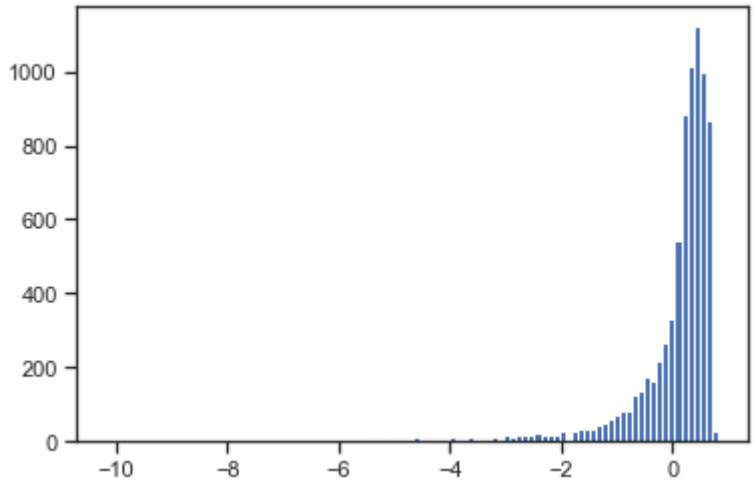

In [ ]:

In [ ]: